Tổng quan Project: XG-Boots Football Analysis

Mục lục

- 1. Giới thiệu
- 2. Mục tiêu
- 3. Dữ liệu
- 4. Phương pháp
- 5. Kết quả
- 6. Web Application
- 7. Cấu trúc Project
- 8. Kết luận & Hướng phát triển

---

1. Giới thiệu

XG-Boots Football Analysis là hệ thống dự đoán kết quả bóng đá quốc tế sử dụng thuật toán **XGBoost** (eXtreme Gradient Boosting). Hệ thống phân tích dữ liệu lịch sử hơn **49,000 trận đấu quốc tế**, tính toán các chỉ số sức mạnh đội tuyển, và đưa ra dự đoán xác suất cho 3 kết quả: **Thắng nhà (Home Win)**, **Hòa (Draw)**, **Thắng khách (Away Win)**.

Project hướng tới ứng dụng cho **World Cup 2026**, cung cấp nền tảng dự đoán dựa trên dữ liệu khoa học thay vì cảm tính.

---

2. Mục tiêu

2.1 Mục tiêu chính

- Xây dựng mô hình **phân loại đa lớp (multi-class classification)** dự đoán kết quả trận đấu bóng đá quốc tế
- Đạt **độ chính xác vượt trội so với baseline** (dự đoán ngẫu nhiên theo phân phối kết quả)
- Cung cấp **xác suất** cho từng kết quả, không chỉ là dự đoán đơn lẻ

2.2 Mục tiêu phụ

- Xác định **features quan trọng nhất** ảnh hưởng đến kết quả trận đấu
- Xây dựng **web application** trực quan hóa kết quả và cho phép dự đoán trận tương lai
- Tạo nền tảng dữ liệu cho các bước tiếp theo (Monte Carlo Simulation, Dashboard tổng hợp)

---

3. Dữ liệu

3.1 Nguồn dữ liệu

Dataset	Nguồn	Mô tả	Kích thước
International Football Results	GitHub (martj42)	Kết quả 49,000+ trận quốc tế từ 1872	3.53 MB
Goalscorers	GitHub (martj42)	Thông tin người ghi bàn	3.10 MB

Dataset	Nguồn	Mô tả	Kích thước
Shootouts	GitHub (martj42)	Kết quả đá penalty	0.03 MB
FIFA World Ranking	Kaggle (cashncarry)	Bảng xếp hạng FIFA chính thức	69,326 entries, 228 đội

3.2 Phạm vi dữ liệu

- **Thời gian:** 2000–2026 (25,013 trận sau khi lọc)
- **Sau feature engineering:** 2005–2026 (20,148 trận — loại giai đoạn cold-start 2000–2004)
- **Số đội tuyển:** 200+ đội tuyển quốc gia
- **Loại giải:** World Cup, Continental (Euro, Copa América, AFCON...), Qualifiers, Friendlies

3.3 Phân phối kết quả

Kết quả	Số trận	Tỷ lệ
Home Win	~8,800	~43.7%
Draw	~4,600	~22.8%
Away Win	~6,700	~33.5%

> Draw là lớp thiểu số — model cần xử lý class imbalance để dự đoán tốt.

---

4. Phương pháp

4.1 Pipeline tổng thể

```
Bước 1: Download Data        Bước 2: Feature Engineering        Bước 3: XGBoost Model
┌─────────────────┐      ┌──────────────────────────┐      ┌──────────────────────────┐
│ results.csv     │      │ Elo Rating               │      │ Train/Test Split         │
│ goalscorers.csv │ ──→  │ FIFA Ranking             │ ──→  │ GridSearchCV             │
│ shootouts.csv   │      │ Poisson Strength         │      │ Train Final Model        │
│ fifa_ranking-*  │      │ Form Features            │      │ Evaluate & Export        │
└─────────────────┘      │ Head-to-Head             │      └──────────────────────────┘
                         └──────────────────────────┘
                          Output: features_matrix.csv      Output: xgboost_model.joblib
                                  (20,148 × 30)                    model_metadata.json
```

4.2 Feature Engineering (Bước 2)

Từ dữ liệu thô, tính toán **23 features** thuộc 6 nhóm. Model XGBoost sử dụng **8 features** chính:

#	Feature	Nhóm	Mô tả	Importance
1	`elo_diff`	Elo Rating	Chênh lệch điểm Elo (home - away)	**44.0%**
2	`rank_diff`	FIFA Ranking	Chênh lệch thứ hạng FIFA (away - home)	**20.3%**
3	`expected_goals_diff`	Poisson	Chênh lệch bàn thắng kỳ vọng	**10.8%**

#	Feature	Nhóm	Mô tả	Importance
4	`is_neutral`	Context	Sân trung lập (1) hay sân nhà (0)	**9.9%**
5	`away_defense_strength`	Poisson	Sức mạnh phòng thủ đội khách	**5.1%**
6	`home_attack_strength`	Poisson	Sức mạnh tấn công đội nhà	**3.9%**
7	`home_form`	Form	Phong độ gần đây đội nhà (5 trận)	**3.2%**
8	`away_form`	Form	Phong độ gần đây đội khách (5 trận)	**2.8%**

> **Insight:** Riêng `elo_diff` + `rank_diff` đã chiếm **64.3%** tầm quan trọng — sức mạnh tổng thể của đội tuyển là yếu tố quyết định nhất.

Nguyên tắc chống Data Leakage

Tất cả features được tính **TRƯỚC** trận đấu diễn ra. Dữ liệu của trận hiện tại chỉ được cập nhật **SAU** khi đã ghi nhận feature. Điều này đảm bảo model không "nhìn thấy tương lai" khi training.

4.3 XGBoost Model (Bước 3)

Thuật toán

XGBoost sử dụng **500 cây quyết định nhỏ (depth=3)**, mỗi cây **sửa lỗi** của các cây trước đó. Kết quả cuối cùng là tổng hợp xác suất từ tất cả 500 cây.

```
Cây #1: nhìn elo_diff  → dự đoán sơ bộ
Cây #2: sửa lỗi cây #1 → nhìn is_neutral
Cây #3: sửa lỗi cây #2 → nhìn away_defense
...
Cây #500: tinh chỉnh cuối cùng
→ Output: P(Home Win), P(Draw), P(Away Win)
```

Hyperparameters (tìm bằng GridSearchCV)

Parameter	Giá trị	Ý nghĩa
`n_estimators`	500	Số lượng cây quyết định
`max_depth`	3	Độ sâu tối đa mỗi cây (giữ đơn giản)
`learning_rate`	0.01	Tốc độ học (nhỏ → học chậm nhưng chính xác)
`subsample`	0.8	Mỗi cây chỉ dùng 80% dữ liệu (chống overfit)
`colsample_bytree`	0.8	Mỗi cây chỉ dùng 80% features
`min_child_weight`	1	Số mẫu tối thiểu trong 1 node lá

Xử lý Class Imbalance

Draw chiếm tỷ lệ thấp nhất (~22.8%), dẫn đến model ban đầu **không bao giờ dự đoán Draw** (recall = 0%). Giải pháp: áp dụng **class weights** theo công thức:

```
weight(class) = total_samples / (n_classes × count_per_class)

→ Away Win: 1.16  (phạt nhẹ — lớp trung bình)
→ Draw:     1.44  (phạt nặng — lớp thiểu số, buộc model chú ý hơn)
→ Home Win: 0.69  (giảm — lớp đa số)
```

Kết quả: Draw recall tăng từ **0%** → **27.2%**.

Training Process

- **Train/Test split theo thời gian:** Train < 2024-01-01 (17,901 trận) | Test ≥ 2024-01-01 (2,247 trận)
- **Cross-validation:** TimeSeriesSplit (5 folds) — giữ đúng thứ tự thời gian
- **GridSearchCV:** 36 tổ hợp hyperparameters × 5 folds = 180 lần training
- **Metric tối ưu:** F1 macro (cân bằng giữa các lớp)

---

5. Kết quả

5.1 Metrics tổng hợp

Metric	Giá trị	Ý nghĩa
Test Accuracy	**56.61%**	Tỷ lệ dự đoán đúng trên tập test
Baseline Accuracy	47.13%	Nếu luôn đoán lớp phổ biến nhất (Home Win)
Improvement	**+9.48%**	Model tốt hơn baseline 9.48 điểm phần trăm
F1 macro	**0.5222**	Trung bình F1 của 3 lớp (cân bằng)
Log Loss	**0.891**	Chất lượng xác suất dự đoán (thấp = tốt)

5.2 Chi tiết theo lớp

Lớp	Precision	Recall	F1	Nhận xét
Home Win	0.60	0.74	0.66	Dự đoán tốt nhất — lớp đa số
Draw	0.35	0.27	0.31	Khó nhất — bóng đá vốn khó đoán hòa
Away Win	0.63	0.57	0.60	Khá tốt

5.3 Confusion Matrix

```
                 Predicted
                 Away  Draw  Home
Actual  Away   [ 430    98   227 ]    57% recall
        Draw   [ 196   140   181 ]    27% recall
        Home   [ 60    162   753 ]    77% recall
```

5.4 Đánh giá

- **56.61% accuracy** là kết quả hợp lý cho bài toán dự đoán bóng đá 3 lớp. Nghiên cứu học thuật thường đạt 50–60% cho bài toán tương tự.
- **Draw vẫn khó đoán** (F1 = 0.31) — đây là thách thức chung trong dự đoán bóng đá vì hòa phụ thuộc nhiều vào yếu tố ngẫu nhiên trong trận.
- **Home Win dễ đoán nhất** (recall 77%) — lợi thế sân nhà là pattern rõ ràng nhất mà model nắm bắt được.
- Model **vượt baseline 9.48%** — chứng tỏ các features thực sự mang thông tin hữu ích.

5.5 Ví dụ dự đoán: Chung kết World Cup 2022

Argentina vs France (sân trung lập, Qatar):

Feature	Giá trị	Giải thích
elo_diff	+112	Argentina Elo cao hơn
rank_diff	+1	Argentina hạng 3, France hạng 4
home_attack_strength	1.65	Argentina tấn công mạnh
away_defense_strength	0.65	France phòng thủ tốt
expected_goals_diff	+0.68	Argentina kỳ vọng ghi nhiều hơn
home_form	0.87	Argentina phong độ cao
away_form	0.80	France phong độ tốt
is_neutral	1	Sân trung lập

Kết quả dự đoán:

```
P(Home Win) = 32.5%
P(Draw)     = 36.0%  ← cao nhất → Prediction: Draw
P(Away Win) = 31.5%

Thực tế: Draw (3-3 sau 120 phút) ✓ ĐÚNG
```

---

6. Web Application

Hệ thống cung cấp **3 trang web** được xây dựng bằng Flask + Chart.js:

6.1 Dashboard (`/`)

Trang tổng quan hiển thị hiệu suất model:

- **4 thẻ thống kê:** Total Matches, Accuracy, F1 Score, Log Loss
- **Feature Importance:** Biểu đồ thanh ngang — click vào từng feature để xem giải thích chi tiết (công thức, ví dụ, cách tính)
- **Confusion Matrix:** Heatmap so sánh dự đoán vs thực tế
- **Result Distribution:** So sánh phân phối thực tế vs dự đoán
- **Probability Calibration:** Đánh giá chất lượng xác suất
- **Model Parameters:** Bảng hyperparameters

6.2 Match Predictor (`/predictor`)

Tra cứu và đánh giá dự đoán cho các trận đấu **đã diễn ra** trong cơ sở dữ liệu:

- **Bộ lọc:** Đội nhà, Đội khách, Giải đấu, Năm
- **Danh sách trận:** Badge Correct/Wrong cho từng trận
- **Panel chi tiết:** Xác suất 3 kết quả (thanh + donut chart), bảng features, so sánh dự đoán vs thực tế

6.3 Future Predictor (`/future`)

Dự đoán kết quả cho **trận đấu tương lai bất kỳ:**

- **Chọn 2 đội** + tùy chọn sân trung lập + nút Swap
- **Biểu đồ xác suất:** Gauge bar 3 màu + donut chart
- **So sánh đội:** Bảng chỉ số (Elo, Rank, Form, Attack, Defense) với highlight xanh/xám
- **Lịch sử đối đầu:** 10 trận gần nhất
- **Phong độ gần đây:** 10 trận gần nhất mỗi đội (W/D/L dots)

6.4 API Endpoints

Web app cung cấp **15 REST API endpoints** để phục vụ dữ liệu:

Endpoint	Mô tả
`/api/model-metrics`	Accuracy, F1, Log Loss
`/api/feature-importance`	Tầm quan trọng 8 features
`/api/confusion-matrix`	Ma trận nhầm lẫn
`/api/result-distribution`	Phân phối kết quả (actual vs predicted)
`/api/probability-calibration`	Dữ liệu calibration
`/api/teams`	Danh sách đội tuyển
`/api/matches`	Lọc trận đấu theo team/tournament/year
`/api/match-features`	Features chi tiết 1 trận
`/api/tournaments`	Danh sách giải đấu
`/api/years`	Danh sách năm
`/api/predict-match`	Dự đoán 1 trận trong DB
`/api/overall-stats`	Thống kê tổng accuracy
`/api/predict-future`	Dự đoán trận tương lai
`/api/team-profile`	Thông tin chi tiết 1 đội

---

7. Cấu trúc Project

```
xg-boots-football-analysis/
│
├── data/
│   ├── raw/                              ← Dữ liệu gốc (Bước 1)
│   │   ├── results.csv                       49,000+ kết quả trận đấu
│   │   ├── goalscorers.csv                   Thông tin người ghi bàn
│   │   ├── shootouts.csv                     Kết quả đá penalty
│   │   └── fifa_ranking-*.csv                FIFA Ranking (3 files)
│   │
│   └── processed/                        ← Dữ liệu đã xử lý (Bước 2)
│       ├── features_matrix.csv               20,148 trận × 30 cột
│       └── elo_ratings.json                  Điểm Elo tất cả đội
│
├── models/                               ← Model đã train (Bước 3)
│   ├── xgboost_model.joblib                  XGBoost trained model
│   └── model_metadata.json                   Params, metrics, importance
│
├── src/                                  ← Source code pipeline
│   ├── step1_download_data.py                Download data từ GitHub
│   ├── step2_preprocessing_and_features.py   Feature engineering (23 features)
│   └── step3_xgboost_model.py                Train XGBoost (8 features)
│
├── web/                                  ← Web application
│   ├── app.py                                Flask backend + 15 API endpoints
│   └── templates/
│       ├── index.html                        Dashboard
│       ├── predictor.html                    Match Predictor
│       └── future.html                       Future Predictor
│
├── docs/                                 ← Tài liệu
│   ├── project_overview.md                   Tổng quan project (file này)
│   ├── step2_analysis_data.md                Phân tích Feature Engineering
│   ├── step3_xgboost_model.md                Phân tích XGBoost Model
│   └── installation_guide.md                 Hướng dẫn cài đặt
│
└── requirements.txt                      ← Dependencies
```

---

8. Kết luận & Hướng phát triển

8.1 Kết luận

- Hệ thống đạt **56.61% accuracy**, vượt baseline **9.48%** — chứng tỏ các features được tính toán mang thông tin dự đoán thực sự.
- **Elo Rating** và **FIFA Ranking** là 2 yếu tố quan trọng nhất (chiếm 64.3% importance), cho thấy sức mạnh tổng thể của đội tuyển là predictor chính.
- **Draw** vẫn là thách thức lớn nhất (F1 = 0.31) — đây là bản chất của bóng đá, không phải lỗi model.
- Web application cung cấp giao diện trực quan để khám phá kết quả và dự đoán trận tương lai.

8.2 Hướng phát triển

Bước tiếp theo	Mô tả
Bước 4: Monte Carlo Simulation	Mô phỏng 10,000+ kịch bản World Cup 2026 dựa trên xác suất từ XGBoost

Bước tiếp theo	Mô tả
Bước 5: Dashboard tổng hợp	Tích hợp kết quả Monte Carlo, hiển thị xác suất vô địch từng đội
Cải thiện model	Thêm features mới (cầu thủ chấn thương, thời tiết, referee), thử các thuật toán khác (LightGBM, Neural Network)
Cập nhật dữ liệu	Tự động cập nhật kết quả trận đấu và FIFA ranking mới nhất

---

Cập nhật lần cuối: 2026-03-17