Bước 2: Analysis Data — Feature Engineering

Mục lục

- 1. Tổng quan
- 2. Nhóm chỉ số Elo Rating
- 3. Nhóm chỉ số FIFA Ranking
- 4. Nhóm chỉ số Poisson (Attack/Defense Strength)
- 5. Nhóm chỉ số Phong độ (Form)
- 6. Nhóm chỉ số Đối đầu (Head-to-Head)
- 7. Nhóm chỉ số Bối cảnh (Context)
- 8. Phân tích bản ghi mẫu: Chung kết World Cup 2022
- 9. Thống kê tổng hợp

---

1. Tổng quan

Bước 2 nhận dữ liệu thô từ Bước 1 (25,013 trận đấu quốc tế từ năm 2000) và tính toán **23 features** chia thành 6 nhóm chính. Sau khi loại bỏ giai đoạn cold-start (2000–2004), output cuối cùng gồm **20,148 trận đấu** từ 2005–2026.

Pipeline xử lý

```
results.csv (raw)
  → Preprocessing (lọc, tạo label)
    → Elo Rating (tính từ lịch sử trận đấu)
      → FIFA Ranking (merge từ dataset ranking)
        → Poisson Strength (rolling 30 trận)
          → Form Features (rolling 5 trận)
            → Head-to-Head (lịch sử đối đầu)
              → features_matrix.csv (output)
```

Nguyên tắc chống Data Leakage

Tất cả features đều được tính **TRƯỚC** trận đấu diễn ra. Dữ liệu của trận hiện tại chỉ được cập nhật **SAU** khi đã ghi nhận giá trị feature. Điều này đảm bảo model không "nhìn thấy tương lai".

---

2. Nhóm chỉ số Elo Rating

Mục đích: Đo lường sức mạnh tổng thể của đội tuyển dựa trên toàn bộ lịch sử thi đấu.

Thuật toán

Hệ thống Elo xuất phát từ cờ vua, được áp dụng cho bóng đá với các điều chỉnh:

- **Elo khởi điểm:** 1500 cho mọi đội
- **K-factor:** K = 30 (mặc định), nhân 1.5 cho giải chính thức (World Cup, Euro, Copa América...)
- **Home advantage:** +100 điểm cho đội nhà (không áp dụng sân trung lập)
- **Goal difference multiplier:** Thắng cách biệt lớn → thay đổi Elo nhiều hơn

- Chênh lệch ≤ 1 bàn: ×1.0
- Chênh lệch = 2 bàn: ×1.5
- Chênh lệch ≥ 3 bàn: ×(11 + goal_diff) / 8

Công thức cập nhật

```
Expected_home = 1 / (1 + 10^((Elo_away - Elo_home_adjusted) / 400))

Elo_new = Elo_old + K × GD_mult × (Actual - Expected)
```

Trong đó `Actual` = 1 (thắng), 0.5 (hòa), 0 (thua).

Features

Feature	Kiểu	Mô tả
`elo_home`	float	Điểm Elo của đội nhà trước trận
`elo_away`	float	Điểm Elo của đội khách trước trận
`elo_diff`	float	`elo_home - elo_away`. Dương = đội nhà mạnh hơn

Phân phối

- **Mean Elo:** ~1,575 (home nhỉnh hơn away do lợi thế sân nhà qua nhiều trận)
- **Range:** 803 – 2,231
- **Top 5 hiện tại:** Spain (2191), Argentina (2154), France (2074), Colombia (2064), England (2061)

---

3. Nhóm chỉ số FIFA Ranking

Mục đích: Bổ sung góc nhìn chính thức từ FIFA — khác biệt với Elo vì FIFA dùng công thức riêng và cập nhật theo chu kỳ.

Nguồn dữ liệu

- 3 file FIFA ranking từ Kaggle: `fifa_ranking-2023-07-20.csv`, `fifa_ranking-2024-04-04.csv`, `fifa_ranking-2024-06-20.csv`
- Tổng cộng **69,326 entries**, **228 đội**, từ 1992 đến 06/2024
- Mapping tên đội được thực hiện để khớp 2 dataset (ví dụ: `USA` → `United States`, `Korea Republic` → `South Korea`)

Cách merge

Với mỗi trận đấu, tìm bản xếp hạng FIFA **gần nhất trước ngày thi đấu** bằng binary search. Đảm bảo 100% trận đấu được match (fill median cho đội không có trong FIFA ranking).

Features

Feature	Kiểu	Mô tả
`rank_home`	int	Thứ hạng FIFA của đội nhà (1 = tốt nhất)

Feature	Kiểu	Mô tả
`rank_away`	int	Thứ hạng FIFA của đội khách
`rank_diff`	int	`rank_away - rank_home`. Dương = đội nhà xếp hạng tốt hơn
`points_home`	float	Điểm FIFA của đội nhà
`points_away`	float	Điểm FIFA của đội khách
`points_diff`	float	`points_home - points_away`. Dương = đội nhà nhiều điểm hơn

Tại sao cần cả Elo lẫn FIFA Ranking?

Tiêu chí	Elo	FIFA Ranking
Nguồn gốc	Tự tính từ kết quả	Chính thức từ FIFA
Cập nhật	Sau mỗi trận	Theo chu kỳ (hàng tháng)
Trọng số giải đấu	Có (competitive × 1.5)	Có (phức tạp hơn)
Ưu điểm	Phản ánh nhanh thay đổi phong độ	Được công nhận rộng rãi, ổn định

Hai hệ thống **tương quan cao nhưng không hoàn toàn giống nhau**, giúp model có thêm thông tin bổ sung.

---

4. Nhóm chỉ số Poisson (Attack/Defense Strength)

Mục đích: Đo lường khả năng ghi bàn (tấn công) và khả năng giữ sạch lưới (phòng thủ) của từng đội, dựa trên mô hình Poisson.

Thuật toán

Dựa trên **rolling window 30 trận gần nhất** của mỗi đội:

```
attack_strength  = avg_goals_scored_by_team  / avg_goals_per_match_globally
defense_strength = avg_goals_conceded_by_team / avg_goals_per_match_globally
```

- `avg_goals_per_match_globally`: trung bình bàn thắng trong 500 trận gần nhất toàn cầu
- Nếu đội chưa đủ 5 trận lịch sử → mặc định = 1.0 (trung bình)

Expected Goals (Poisson Lambda)

```
expected_goals_home = home_attack × away_defense × avg_goals
expected_goals_away = away_attack × home_defense × avg_goals
```

Đây là **số bàn thắng kỳ vọng** (lambda) để đưa vào phân phối Poisson, tính xác suất cho từng tỉ số cụ thể.

Features

Feature	Kiểu	Mô tả
`home_attack_strength`	float	Chỉ số tấn công đội nhà. >1 = mạnh hơn TB
`home_defense_strength`	float	Chỉ số phòng thủ đội nhà. <1 = phòng thủ tốt hơn TB
`away_attack_strength`	float	Chỉ số tấn công đội khách
`away_defense_strength`	float	Chỉ số phòng thủ đội khách
`expected_goals_home`	float	Số bàn kỳ vọng đội nhà ghi
`expected_goals_away`	float	Số bàn kỳ vọng đội khách ghi
`expected_goals_diff`	float	`expected_goals_home - expected_goals_away`

Cách đọc

- `attack_strength = 1.65` → Đội ghi bàn nhiều hơn trung bình giải 65%
- `defense_strength = 0.34` → Đội chỉ để lọt lưới bằng 34% so với TB giải (phòng thủ cực tốt)
- `defense_strength = 1.5` → Đội để lọt lưới nhiều hơn TB giải 50% (phòng thủ yếu)

---

5. Nhóm chỉ số Phong độ (Form)

Mục đích: Đo lường phong độ gần đây (momentum) của đội tuyển trong **5 trận gần nhất**, bất kể giải đấu nào.

Thuật toán

```
form = mean(points_last_5) / 3.0
```

Trong đó: Thắng = 3 điểm, Hòa = 1 điểm, Thua = 0 điểm. Kết quả được normalize về khoảng [0, 1].

```
goal_diff_5 = mean(goal_difference_last_5)
```

Features

Feature	Kiểu	Range	Mô tả
`home_form`	float	0.0 – 1.0	Phong độ đội nhà. 1.0 = thắng cả 5 trận
`away_form`	float	0.0 – 1.0	Phong độ đội khách
`goal_diff_home_5`	float	~(-15, +11)	Hiệu số bàn thắng TB trong 5 trận gần nhất đội nhà
`goal_diff_away_5`	float	~(-15, +7)	Hiệu số bàn thắng TB đội khách

Cách đọc

- `form = 0.87` → Khoảng 13 điểm / 15 điểm tối đa (4 thắng + 1 hòa)
- `form = 0.33` → Khoảng 5 điểm / 15 (1 thắng + 2 hòa + 2 thua)
- `goal_diff_5 = +1.6` → Trung bình thắng cách biệt 1.6 bàn trong 5 trận gần nhất

---

6. Nhóm chỉ số Đối đầu (Head-to-Head)

Mục đích: Đo lường lịch sử đối đầu trực tiếp giữa 2 đội. Một số cặp đấu có "duyên nợ" đặc biệt không thể hiện qua Elo hay ranking.

Thuật toán

```
h2h_win_rate = số trận đội nhà thắng đội khách / tổng số trận đối đầu
```

- Chỉ tính khi 2 đội đã gặp nhau **ít nhất 3 lần**, nếu không → mặc định 0.5
- Tính từ góc nhìn của đội nhà (home team's perspective)

Features

Feature	Kiểu	Range	Mô tả
`h2h_win_rate`	float	0.0 – 1.0	Tỉ lệ thắng của đội nhà trong lịch sử đối đầu

Cách đọc

- `h2h_win_rate = 0.67` → Đội nhà thắng 2/3 lần đối đầu trực tiếp
- `h2h_win_rate = 0.50` → Cân bằng hoặc chưa đủ dữ liệu

---

7. Nhóm chỉ số Bối cảnh (Context)

Mục đích: Các yếu tố ngoài sức mạnh đội bóng ảnh hưởng đến kết quả trận đấu.

Features

Feature	Kiểu	Giá trị	Mô tả
`is_neutral`	int	0 hoặc 1	1 = sân trung lập (World Cup, Confederations Cup...)
`is_competitive`	int	0 hoặc 1	1 = giải chính thức (không phải giao hữu)

Tầm quan trọng

- **Sân trung lập:** Loại bỏ lợi thế sân nhà. World Cup 2026 hầu hết là sân trung lập (trừ USA, Mexico, Canada)
- **Giải chính thức:** Các đội thường thi đấu nghiêm túc hơn giao hữu → kết quả đáng tin cậy hơn

Phân phối trong dataset

- 29.3% trận đấu trên sân trung lập
- 47.3% trận đấu thuộc giải chính thức

---

8. Phân tích bản ghi mẫu: Chung kết World Cup 2022

Argentina vs France — 18/12/2022 (3-3, Argentina thắng penalty)

Bảng dưới đây mô tả **tất cả 30 trường dữ liệu** trong 1 bản ghi của `features_matrix.csv`, chia rõ:

- **Nguồn gốc:** Lấy trực tiếp từ file nào, hoặc được tính bằng công thức gì
- **XGBoost Input:** Trường nào được đưa vào model, trường nào chỉ là metadata

---

8.1 Nhóm Metadata (7 trường) — KHÔNG đưa vào XGBoost

Các trường này dùng để **nhận diện trận đấu** và **tạo label**, không phải feature cho model.

#	Trường	Giá trị mẫu	Nguồn gốc	Vai trò
1	`date`	`2022-12-18`	Lấy trực tiếp từ cột `date` trong `data/raw/results.csv`	Dùng để sắp xếp thời gian, chia train/test
2	`home_team`	`Argentina`	Lấy trực tiếp từ cột `home_team` trong `results.csv`	Nhận diện đội nhà
3	`away_team`	`France`	Lấy trực tiếp từ cột `away_team` trong `results.csv`	Nhận diện đội khách
4	`home_score`	`3`	Lấy trực tiếp từ cột `home_score` trong `results.csv`	Dùng để tính `result`, không đưa vào model (vì đây là kết quả sau trận)
5	`away_score`	`3`	Lấy trực tiếp từ cột `away_score` trong `results.csv`	Tương tự `home_score`
6	`tournament`	`FIFA World Cup`	Lấy trực tiếp từ cột `tournament` trong `results.csv`	Dùng để phân loại, không đưa trực tiếp vào model
7	`result`	`1` (Draw)	**Tính từ:** `home_score` vs `away_score` → 2=Home Win, 1=Draw, 0=Away Win	**TARGET LABEL** — biến mục tiêu mà XGBoost cần dự đoán

---

8.2 Nhóm Elo (3 trường) — INPUT cho XGBoost

#	Trường	Giá trị mẫu	Nguồn gốc	Công thức / Cách tính
8	`elo_home`	`2173.24`	**Tự tính** từ toàn bộ lịch sử `results.csv` (từ năm 2000)	Bắt đầu = 1500. Sau mỗi trận: `Elo_new = Elo_old + K × GD_mult × (Actual - Expected)`. K=30 (×1.5 nếu giải chính thức). Giá trị này là Elo của Argentina **trước** trận chung kết, tích lũy qua hàng trăm trận trước đó
9	`elo_away`	`2061.26`	**Tự tính** tương tự `elo_home`	Elo của France tích lũy đến trước trận này
10	`elo_diff`	`+111.97`	**Tính từ:** `elo_home - elo_away`	Dương → đội nhà mạnh hơn. +112 ≈ Argentina thắng 65% trên sân trung lập

> **Lưu ý:** Elo được tính tuần tự trận-by-trận. Giá trị Elo của 1 trận phụ thuộc vào KẾT QUẢ tất cả trận trước đó, nhưng KHÔNG dùng kết quả trận hiện tại (chống data leakage).

8.3 Nhóm FIFA Ranking (6 trường) — INPUT cho XGBoost

#	Trường	Giá trị mẫu	Nguồn gốc	Công thức / Cách tính
11	`rank_home`	`3`	Lấy từ `data/raw/fifa_ranking-*.csv`	Tra cứu cột `rank` theo tên đội (`country_full`) + ngày gần nhất ≤ ngày trận đấu (`rank_date` ≤ `2022-12-18`). Mapping tên: `Korea Republic` → `South Korea`, `USA` → `United States`...
12	`rank_away`	`4`	Tương tự `rank_home`	Tra cứu rank của France tại thời điểm gần nhất trước trận
13	`rank_diff`	`+1`	**Tính từ:** `rank_away - rank_home`	Dương → đội nhà xếp hạng tốt hơn (số nhỏ = hạng cao). France hạng 4, Argentina hạng 3 → 4-3 = +1
14	`points_home`	`1773.88`	Lấy từ cột `total_points` trong `fifa_ranking-*.csv`	Điểm FIFA chính thức của Argentina tại kỳ ranking gần nhất
15	`points_away`	`1759.78`	Tương tự `points_home`	Điểm FIFA của France
16	`points_diff`	`+14.10`	**Tính từ:** `points_home - points_away`	Dương → đội nhà nhiều điểm FIFA hơn. Chênh lệch rất nhỏ (+14/1773 ≈ 0.8%)

> **So sánh Elo vs FIFA:** Elo cho thấy khoảng cách lớn (+112), FIFA Ranking gần ngang (+1 hạng, +14 điểm). Cả 2 hệ thống cùng đưa vào model để XGBoost tự học cái nào quan trọng hơn.

8.4 Nhóm Poisson Strength (7 trường) — INPUT cho XGBoost

#	Trường	Giá trị mẫu	Nguồn gốc	Công thức / Cách tính
17	`home_attack_strength`	`1.6458`	**Tự tính** từ `results.csv`	`mean(goals_scored_by_Argentina_in_last_` `mean(all_goals_last_500_matches)`. Argent bàn/trận ÷ TB giải 1.4 = **1.65** → tấn công mạ 65%
18	`home_defense_strength`	`0.3396`	**Tự tính** từ `results.csv`	`mean(goals_conceded_by_Argentina_in_las` `/ mean(all_goals_last_500_matches)`. Arge lưới TB 0.47 bàn/trận ÷ TB giải 1.4 = **0.34** → bằng 34% so với TB
19	`away_attack_strength`	`1.5935`	**Tự tính** tương tự	France ghi bàn nhiều hơn TB giải 59%
20	`away_defense_strength`	`0.6531`	**Tự tính** tương tự	France để thủng lưới bằng 65% so với TB (p nhưng kém Argentina)
21	`expected_goals_home`	`1.3715`	**Tính từ:** `home_attack × away_defense × avg_goals`	`1.6458 × 0.6531 × 1.4 = 1.37` → mô hình Argentina ghi ~1.4 bàn
22	`expected_goals_away`	`0.6905`	**Tính từ:** `away_attack × home_defense × avg_goals`	`1.5935 × 0.3396 × 1.4 = 0.69` → mô hình France ghi ~0.7 bàn
23	`expected_goals_diff`	`+0.6809`	**Tính từ:** `expected_goals_home - expected_goals_away`	`1.37 - 0.69 = +0.68` → Argentina kỳ vọng ~0.7 bàn

> **Rolling window = 30 trận:** Mỗi chỉ số dựa trên 30 trận gần nhất của đội đó (bất kể đá nhà hay khách, bất kể giải nào). Nếu đội chưa đủ 5 trận → mặc định = 1.0.

8.5 Nhóm Form (4 trường) — INPUT cho XGBoost

#	Trường	Giá trị mẫu	Nguồn gốc	Công thức / Cách tính
24	`home_form`	`0.8667`	**Tự tính** từ `results.csv`	Lấy 5 trận gần nhất của Argentina trước 18/12/2022. Tính điểm: Thắng=3, Hòa=1, Thua=0. `form = mean(points) / 3`. VD: 4 thắng + 1 hòa = (3+3+3+3+1)/5 = 2.6 → 2.6/3 = **0.867**
25	`away_form`	`0.8000`	**Tự tính** tương tự	5 trận gần nhất của France: 4 thắng + 1 thua = (3+3+3+3+0)/5 = 2.4 → 2.4/3 = **0.80**
26	`goal_diff_home_5`	`+1.6`	**Tự tính** từ `results.csv`	`mean(goal_diff_last_5_matches_of_Argentina)`. VD: nếu 5 trận gần nhất thắng 2-1, 2-0, 3-0, 1-0, 2-1 → hiệu số = +1,+2,+3,+1,+1 → TB = **+1.6**
27	`goal_diff_away_5`	`+1.0`	**Tự tính** tương tự	Hiệu số bàn thắng TB 5 trận gần nhất của France

> **Rolling window = 5 trận:** Phong độ ngắn hạn, phản ánh momentum hiện tại. Khác Poisson (30 trận) phản ánh năng lực dài hạn.

8.6 Nhóm H2H (1 trường) — INPUT cho XGBoost

#	Trường	Giá trị mẫu	Nguồn gốc	Công thức / Cách tính
28	`h2h_win_rate`	`0.6667`	**Tự tính** từ `results.csv`	Đếm tất cả trận Argentina vs France **trước** 18/12/2022 trong dataset (từ năm 2000). `h2h = số_trận_Argentina_thắng / tổng_số_trận`. VD: gặp nhau 3 lần, Argentina thắng 2 → 2/3 = **0.667**. Nếu < 3 trận đối đầu → mặc định 0.5

> **Góc nhìn:** Luôn tính từ perspective của `home_team`. Nếu trận khác France là home, giá trị sẽ khác.

8.7 Nhóm Context (2 trường) — INPUT cho XGBoost

#	Trường	Giá trị mẫu	Nguồn gốc	Công thức / Cách tính
29	`is_neutral`	`1`	Lấy trực tiếp từ cột `neutral` trong `results.csv`, convert True/False → 1/0	1 = sân trung lập (Qatar). World Cup đa số sân trung lập trừ đội chủ nhà
30	`is_competitive`	`1`	**Tự tính** từ cột `tournament` trong `results.csv`	Kiểm tra tên giải có nằm trong danh sách giải chính thức không: FIFA World Cup, UEFA Euro, Copa América, AFC Asian Cup, African Cup of Nations, UEFA Nations League... → 1 = có, 0 = không (giao hữu)

8.8 Sơ đồ tổng hợp: Nguồn gốc → Feature → XGBoost

```
┌──────────────────────────┐      ┌──────────────────────────┐
│   data/raw/results.csv   │      │ data/raw/fifa_ranking-   │
│                          │      │ *.csv (từ Kaggle)        │
│ • date                   │      │                          │
│ • home_team, away_team   │      │ • rank, total_points     │
│ • home_score,away_score  │      │ • country_full           │
│ • tournament             │      │ • rank_date              │
│ • neutral                │      │                          │
└──────────┬───────────────┘      └──────────┬───────────────┘
           │                                 │
           │ Preprocessing                   │ Merge by team+date
           ▼                                 ▼
┌──────────────────────────────────────────────────────────┐
│              step2_preprocessing_and_features.py          │
│                                                           │
│  ┌─ LẤY TRỰC TIẾP ──────────────────────────────────┐ │
│  │ date, home_team, away_team, home_score, away_score,  │ │
│  │ tournament, is_neutral                              │ │
│  └──────────────────────────────────────────────────┘ │
```

```
│                                                                │
│   ┌─ TÍNH TỪ home_score/away_score ──────────────────────┐ │
│   │ result (target label: 0/1/2)                          │ │
│   └──────────────────────────────────────────────────────┘ │
│                                                                │
│   ┌─ TÍNH TUẦN TỰ QUA TỪNG TRẬN (Elo algorithm) ──────────┐ │
│   │ elo_home, elo_away, elo_diff                          │ │
│   └──────────────────────────────────────────────────────┘ │
│                                                                │
│   ┌─ MERGE TỪ FIFA RANKING CSV ──────────────────────────┐ │
│   │ rank_home, rank_away, rank_diff                       │ │
│   │ points_home, points_away, points_diff                 │ │
│   └──────────────────────────────────────────────────────┘ │
│                                                                │
│   ┌─ TÍNH ROLLING 30 TRẬN (Poisson logic) ───────────────┐ │
│   │ home/away_attack_strength, home/away_defense_strength │ │
│   │ expected_goals_home/away/diff                         │ │
│   └──────────────────────────────────────────────────────┘ │
│                                                                │
│   ┌─ TÍNH ROLLING 5 TRẬN ────────────────────────────────┐ │
│   │ home_form, away_form, goal_diff_home_5/away_5         │ │
│   └──────────────────────────────────────────────────────┘ │
│                                                                │
│   ┌─ TÍNH TỪ LỊCH SỬ ĐỐI ĐẦU ────────────────────────────┐ │
│   │ h2h_win_rate                                          │ │
│   └──────────────────────────────────────────────────────┘ │
│                                                                │
│   ┌─ TÍNH TỪ tournament name ────────────────────────────┐ │
│   │ is_competitive                                        │ │
│   └──────────────────────────────────────────────────────┘ │
└────────────────────────────────────────────────────────────────┘
                                │
                                │
                                ▼
┌────────────────────────────────────────────────────────────────┐
│            data/processed/features_matrix.csv                  │
│                                                                │
│  METADATA (7 cột) ─── Không đưa vào XGBoost                   │
│  │ date, home_team, away_team, home_score, away_score,        │
│  │ tournament, result (= TARGET LABEL)                        │
│  │                                                            │
│  ALL FEATURES (23 cột) ─── Có sẵn trong features_matrix       │
│  │ elo_home, elo_away, elo_diff                       [Elo]   │
│  │ rank_home, rank_away, rank_diff              [FIFA Rank]   │
│  │ points_home, points_away, points_diff        [FIFA Pts]    │
│  │ home/away_attack_strength                    [Poisson]     │
│  │ home/away_defense_strength                   [Poisson]     │
│  │ expected_goals_home/away/diff                [Poisson]     │
│  │ home_form, away_form                           [Form]      │
│  │ goal_diff_home_5, goal_diff_away_5             [Form]      │
│  │ h2h_win_rate                                    [H2H]      │
│  │ is_neutral, is_competitive                  [Context]      │
│  │                                                            │
│  XGBOOST INPUT (8 cột) ─── Đầu vào chính thức Bước 3         │
│  │ ① elo_diff                            [Sức mạnh]          │
│  │ ② rank_diff                           [Sức mạnh]          │
│  │ ③ home_attack_strength                [Poisson]           │
│  │ ④ away_defense_strength               [Poisson]           │
│  │ ⑤ expected_goals_diff                 [Poisson]           │
│  │ ⑥ home_form                           [Form]              │
│  │ ⑦ away_form                           [Form]              │
│  │ ⑧ is_neutral                          [Bối cảnh]          │
└────────────────────────────────────────────────────────────────┘
                                │
                                ▼
┌────────────────────────────────────────────────────────────────┐
│              Bước 3: XGBoost Model                             │
│                                                                │
│  X = 8 features       →  XGBClassifier  →   Predictions        │
│  y = result (0/1/2)      (multi:softprob)   [P_win,            │
│                                              P_draw,           │
```

```
│                                          P_loss]        │
└─────────────────────────────────────────────────────────┘
```

8.9 Tổng kết bản ghi mẫu

Trận chung kết Argentina vs France: Mọi chỉ số đều nghiêng về Argentina — Elo cao hơn (+112), FIFA ranking tốt hơn (hạng 3 vs 4), tấn công mạnh hơn (1.65 vs 1.59), phòng thủ chắc hơn (0.34 vs 0.65), phong độ tốt hơn (0.87 vs 0.80), lịch sử đối đầu áp đảo (67%). Tuy nhiên kết quả thực tế là **hòa 3-3** — Mbappé lập hat-trick giúp France cân bằng.

Điều này minh họa:

1. **Bóng đá có tính bất định cao** — model chỉ dự đoán xác suất, không phải kết quả chắc chắn
2. **XGBoost nên output xác suất** (ví dụ: P(Win)=55%, P(Draw)=25%, P(Loss)=20%) thay vì chỉ 1 nhãn
3. **Monte Carlo simulation** (Bước 4) cần chạy hàng ngàn lần để phản ánh sự biến động này

---

9. Thống kê tổng hợp

Dataset cuối cùng

Thông số	Giá trị
Tổng số trận	20,148
Khoảng thời gian	01/2005 – 01/2026
Số đội tuyển	312
Số features	23
Missing values	0
Duplicate rows	0

Phân phối kết quả (Target Variable)

Kết quả	Số trận	Tỉ lệ
Home Win (result=2)	9,656	47.9%
Draw (result=1)	4,677	23.2%
Away Win (result=0)	5,815	28.9%

> **Lưu ý:** Class imbalance nhẹ — Home Win chiếm gần 50%. XGBoost (Bước 3) cần cân nhắc class weights hoặc stratified sampling.

Bảng tổng hợp Features

#	Feature	Nhóm	Min	Mean	Max	Mô tả
1	`elo_home`	Elo	803	1,582	2,225	Điểm Elo đội nhà

#	Feature	Nhóm	Min	Mean	Max	Mô tả
2	`elo_away`	Elo	805	1,564	2,232	Điểm Elo đội khách
3	`elo_diff`	Elo	-1,221	+18	+1,186	Chênh lệch Elo
4	`rank_home`	FIFA	1	83	211	Hạng FIFA đội nhà
5	`rank_away`	FIFA	1	86	211	Hạng FIFA đội khách
6	`rank_diff`	FIFA	-210	+3	+209	Chênh lệch hạng
7	`points_home`	FIFA	0	796	2,164	Điểm FIFA đội nhà
8	`points_away`	FIFA	0	780	2,164	Điểm FIFA đội khách
9	`points_diff`	FIFA	-1,757	+16	+1,596	Chênh lệch điểm FIFA
10	`home_attack_strength`	Poisson	0.00	1.02	4.60	Chỉ số tấn công đội nhà
11	`home_defense_strength`	Poisson	0.16	0.99	7.21	Chỉ số phòng thủ đội nhà
12	`away_attack_strength`	Poisson	0.00	0.99	4.22	Chỉ số tấn công đội khách
13	`away_defense_strength`	Poisson	0.16	1.03	11.02	Chỉ số phòng thủ đội khách
14	`expected_goals_home`	Poisson	0.00	1.40	17.63	Bàn thắng kỳ vọng đội nhà
15	`expected_goals_away`	Poisson	0.00	1.31	16.29	Bàn thắng kỳ vọng đội khách
16	`expected_goals_diff`	Poisson	-16.14	+0.09	+17.21	Chênh lệch bàn thắng kỳ vọng
17	`home_form`	Form	0.00	0.47	1.00	Phong độ đội nhà (5 trận)
18	`away_form`	Form	0.00	0.46	1.00	Phong độ đội khách (5 trận)
19	`goal_diff_home_5`	Form	-15.2	+0.04	+11.0	Hiệu số bàn thắng TB (5 trận) đội nhà
20	`goal_diff_away_5`	Form	-14.6	-0.04	+6.2	Hiệu số bàn thắng TB (5 trận) đội khách
21	`h2h_win_rate`	H2H	0.00	0.44	1.00	Tỉ lệ thắng đối đầu trực tiếp
22	`is_neutral`	Context	0	0.29	1	Sân trung lập
23	`is_competitive`	Context	0	0.47	1	Giải chính thức

Output Files

File	Đường dẫn	Mô tả
Feature Matrix	`data/processed/features_matrix.csv`	Ma trận 20,148 × 30 (7 metadata + 23 features)
Elo Ratings	`data/processed/elo_ratings.json`	Điểm Elo hiện tại của tất cả đội (dùng cho Bước 3/4)

Tài liệu được tạo tự động từ pipeline `src/step2_preprocessing_and_features.py`